

gat_vol2pk_explained

Giải thích: “multi-head GAT trên cạnh có hướng volume→volatility (vol→PK) lead-lag”

Tài liệu giải thích ý nghĩa và **cách tính** của cụm từ “*a real multi-head Graph Attention Network (GAT) over a directed volume-to-volatility (vol→PK) lead-lag edge*”. Công thức lấy theo code: `baselines/2026-08-15_trackA_gat_edge/code/gat.py` (GAT) và `baselines/2026-08-11_eda_gnn_baseline/code/edges.py` (cạnh vol→PK).

Cụm từ gồm 3 phần: (A) **cạnh có hướng vol→PK lead-lag** (đồ thị nối mã nào với mã nào), (B) **GAT đa đầu (multi-head)** (cách lan truyền thông tin trên đồ thị đó), (C) chữ “**real**” (GAT tự viết đầy đủ, không phải xấp xỉ).

A. Cạnh có hướng volume→volatility (vol→PK) lead-lag

Ý tưởng: cú sốc **khối lượng** của mã nguồn i hôm nay có thể **báo trước** biến động (Parkinson) của mã đích j **ngày mai**. Đây là quan hệ **có hướng** ($i \rightarrow j$) và **dẫn-trễ** (lead-lag, lệch 1 ngày), khác với tương quan **đồng thời** (contemporaneous) vốn chủ yếu phản ánh nhân tố thị trường chung.

Cách tính (ước lượng trên TRAIN, rồi đóng băng):

- Với mỗi mã, lấy 2 chuỗi trên các ngày **train**:
 - $\text{volume_shock}_i(t)$ = z-score rolling-22 của $\log(1+\text{volume}_i(t))$ (cú sốc khối lượng bất thường).
 - $\sqrt{PK}_j(t)$ = căn bậc hai của Parkinson variance của mã j .
- Tính **tương quan dẫn-trễ 1 ngày** giữa cú sốc khối lượng của i (tại t) và biến động của j (tại $t+1$):

$$\rho_{i \rightarrow j} = \text{corr}(\text{volume_shock}_i(t), \sqrt{PK}_j(t+1)),$$

chỉ trên các ngày train chung của cặp (i, j) .

- Với **mỗi mã đích j** , chọn **Top-5 mã nguồn i** có $|\rho_{i \rightarrow j}|$ lớn nhất $\rightarrow$ đó là 5 cạnh đi vào j . Ma trận kề A là **có hướng** ($i \rightarrow j$), **không đối xứng**, và giữ **self-loop** (mỗi node nối chính nó).

4. A được **đóng băng** (frozen): dùng y nguyên cho validation/test (không ước lượng lại) → **không leakage**. Mã không có chuỗi khối lượng (vd LPB) không làm nguồn.

Ví dụ: nếu trên train, cú sốc khối lượng của HPG hôm nay tương quan mạnh với biến động của HSG ngày mai, thì có cạnh **HPG** → **HSG**; khi dự báo HSG, mô hình được “nhìn” thông tin của HPG qua cạnh này.

Vì sao chọn cạnh này thay vì k-NN tương quan trên PK: tương quan PK–PK **đồng thời** $\approx$ nhân tố thị trường chung (đã được HAR bắt gián tiếp), không có tính **dự báo**; còn vol→PK là **có hướng + dẫn trễ** nên về lý thuyết mang thông tin dùng được ngoài mẫu.

B. Mạng chú ý đồ thị đa đầu (multi-head GAT)

GAT lan truyền thông tin giữa các mã **theo trọng số chú ý (attention)** học được, chỉ đọc các cạnh của A. Trong mô hình này, **đầu vào node là feature THÔ tại ngày cuối** `node_raw = price[:, :, -1, :]` (5 feature), **không phải** trạng thái ẩn của LSTM.

Ký hiệu: h_i = vector feature của node i ; H = số đầu (heads) = 4; W = ma trận biến đổi tuyến tính (mỗi head). Một lớp GAT tính như sau (theo `gat.py`):

1. **Biến đổi tuyến tính:** $z_i = Wh_i$ (chiều mỗi node sang không gian ẩn, mỗi head riêng).
2. **Điểm chú ý thô** giữa đích i và nguồn j :

$$e_{ij} = \text{LeakyReLU}(a_{\text{dst}}^\top z_i + a_{\text{src}}^\top z_j),$$

với $a_{\text{dst}}, a_{\text{src}}$ là vector chú ý học được (mỗi head).

3. **Che theo đồ thị:** chỉ giữ e_{ij} khi $A[i, j] > \theta$ (có cạnh $j \rightarrow i$); còn lại đặt $-\infty$.
4. **Chuẩn hoá softmax trên các NGUỒN j :**

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k: A[i, k] > 0} \exp(e_{ik})}.$$

(Node cô lập $\rightarrow$ cả hàng $-\infty \rightarrow \text{nan_to_num}$ đưa về 0.)

5. **Tổng hợp có trọng số + phi tuyến:**

$$h'_i = \text{ELU}\left(\sum_j \alpha_{ij} z_j\right).$$

6. **Đa đầu (multi-head):** làm song song $H=4$ head rồi **nối (concat)** kết quả.

Kích thước thực tế (2 lớp): - Lớp 1: `GATLayer(5  $\rightarrow$  64, heads=4)  $\rightarrow$  concat = [B, N, 256]`. - Lớp 2: `GATLayer(256  $\rightarrow$  64, heads=4)  $\rightarrow$  h_gnn = [B, N, 256]`.

Ý nghĩa: mỗi mã đích j **tổng hợp có chọn lọc** (qua trọng số α) feature khối lượng/biến động của Top-5 mã nguồn nối tới nó — tức “học xem nên nghe mã nguồn nào nhiều hơn”.

C. “real” GAT nghĩa là gì

“real” = GAT đa đầu tự viết đầy đủ kiểu Veličković (có ma trận W , vector chú ý a , softmax theo cạnh, ELU, multi-head) — **không** phải một xấp xỉ tuyến tính hay lớp giả. Do repo không cài `torch_geometric`, lớp GAT được hiện thực trực tiếp bằng PyTorch trong `gat.py`.

D. Ghép vào mô hình

$$h_{\text{gmn}} = \text{GAT}_2(\text{GAT}_1(\text{node_raw}, A), A),$$

rồi nối 3 nhánh song song: $h = [h_{\text{lstm}}(64) \parallel h_{\text{gmn}}(256) \parallel \text{gated_news}(64)] \in \mathbb{R}^{384}$, đưa qua head (Linear→ReLU→Dropout→Linear) + sản dương (softplus) ra dự báo Parkinson tại $t+h$. Biến thể **minus_graph** = bỏ hẳn nhánh GAT này (head còn 128).

E. Trực giác và kết quả thực nghiệm

Cạnh $\text{vol} \rightarrow \text{PK}$ cho GAT **cơ hội tốt nhất** để bắt spillover có hướng (đầu vào thô chứa thẳng `volume_zscore`, đúng đại lượng cạnh dựa vào). Tuy nhiên, đo trên test (Diebold-Mariano đa-metric, 3 seed): **bỏ nhánh GAT không làm mô hình tệ đi có ý nghĩa trên MSE/RMSE/R² ở hầu hết horizon**, và trên QLIKE việc bỏ graph còn **giảm** QLIKE ở $h1/h22$ — tức graph **không thêm giá trị ngoài mẫu ổn định**. Kết quả này nhất quán với phân tích EDA trước đó (nhân tố thị trường chung chi phối đồng biến động chéo-mã) và với văn liệu (GNNHAR trên DJIA-30: spillover đa-bước không cho lợi thế rõ dưới Model Confidence Set).

Tham chiếu code: `gat.py` (lớp `GATLayer`), `model.py` (ghép nhánh + head + sản dương), `edges.py` (`build_vol2pk_adjacency`: cạnh $\text{vol} \rightarrow \text{PK}$ Top-5 train-only, đóng băng).