

Dự đoán độ biến động chứng khoán cho thị trường Việt Nam

Tóm tắt

Dự báo độ biến động là cơ sở để thiết lập hạn mức rủi ro, ký quỹ và định giá quyền chọn trên thị trường chứng khoán Việt Nam. Nghiên cứu này hướng tới dự báo độ biến động cho cổ phiếu Việt Nam nói chung và sử dụng các cổ phiếu thành phần VN30 (nhóm cổ phiếu thanh khoản cao nhất trên Sở Giao dịch Chứng khoán TP. Hồ Chí Minh) làm nghiên cứu tình huống thực nghiệm. Hai tín hiệu có cấu trúc mà một mô hình Heterogeneous AutoRegressive (HAR) đơn biến bỏ qua là tin tức tiếng Việt và hiệu ứng lan truyền chéo giữa các cổ phiếu. Nghiên cứu đề xuất một mô hình đa nhánh song song hợp nhất ba nhánh cho dự báo phương sai Parkinson đa horizon của một mã cổ phiếu: một LSTM giá theo từng node trên năm đặc trưng node, một mạng Graph Attention Network (GAT) đa đầu thực sự trên một **cạnh dẫn-trễ có hướng khối lượng-đến-độ biến động (vol→PK)**, và một LSTM tin tức PhoBERT với công theo từng mã. Nhánh GAT tiêu thụ vector đặc trưng node thô tại gốc dự báo thay vì trạng thái ẩn của LSTM, điều này khớp với ngữ nghĩa của cạnh (một cú sốc khối lượng của mã nguồn tại t dẫn trước độ biến động của mã đích tại $t+1$) và giữ cho nhánh đồ thị là một góc nhìn cắt ngang độc lập phục vụ một nghiên cứu ablation công bằng. Mô hình được đánh giá bằng một **ablation**: từ mô hình đầy đủ, mỗi biến thể được huấn luyện lại bằng cách gỡ đúng một thành phần (minus-graph gỡ toàn bộ nhánh GAT, minus-gate gỡ công theo từng mã, minus-news gỡ nhánh tin tức), và đóng góp của mỗi thành phần được đo bằng $\text{effect}(X) = \text{QLIKE}(\text{FULL}) - \text{QLIKE}(\text{FULL} - X)$ trên tập kiểm tra tách riêng (held-out), kèm kiểm định Diebold-Mariano để xét ý nghĩa thống kê. HAR cổ điển là baseline tham chiếu. Qua năm seed và bốn horizon, khác biệt giữa HAR, mô hình đầy đủ, và các biến thể ablation là nhỏ trên mọi metric. Trên MSE, RMSE, và R^2 các giá trị trung bình của các cấu hình nằm trong khoảng 1% so với nhau và giá trị tốt nhất luân phiên qua các horizon; trên MAE khác biệt cũng nhỏ tương tự và giá trị trung bình thấp nhất thay đổi theo horizon. Trên QLIKE, HAR có giá trị trung bình thấp nhất tại h5, h10, và h22 còn minus_graph có giá trị thấp nhất tại h1. Các kiểm định Diebold-Mariano trên dự báo seed-ensembled, chạy trên các họ hàm mất mát QLIKE, sai số bình phương, và sai số tuyệt đối, cho thấy không mô hình nào được ưu tiên trên cả ba: so với HAR, mô hình đầy đủ không có khác biệt QLIKE có ý nghĩa tại h1, h5, và h10 và có QLIKE cao hơn có ý nghĩa tại h22, không có khác biệt sai số bình phương có ý nghĩa tại bất kỳ horizon nào, và có mất mát sai số tuyệt đối thấp hơn có ý nghĩa tại h5. Các thao tác gỡ thành phần trong ablation có ý nghĩa trên một số họ mất mát và horizon nhưng không có ý nghĩa ở số khác, nên không có kết luận ablation nào giữ nguyên đồng nhất qua cả ba hàm mất mát và bốn

horizon. Qua cả năm metric, không cấu hình nào vượt HAR một cách nhất quán hoặc có ý nghĩa. Đóng góp của bài báo này là một quy trình quy đóng góp dựa trên ablation an toàn với rò rỉ dữ liệu (leakage-safe) cho một mô hình graph-attention tin tức với hiệu ứng lan truyền có hướng, đối chiếu với một baseline HAR mạnh trên dữ liệu VN30 hàng ngày thừa.

Từ khóa: dự báo độ biến động; mạng graph attention; hiệu ứng lan truyền có hướng; tin tức tài chính; PhoBERT; thị trường mới nổi.

1. Giới thiệu

Dự báo độ biến động chi phối các quyết định rủi ro hàng ngày của mọi bộ phận giao dịch cổ phiếu Việt Nam. Nghiên cứu này giải quyết bài toán dự báo độ biến động cổ phiếu cho thị trường Việt Nam nói chung; rõ VN30 (khoảng ba mươi cổ phiếu thanh khoản cao nhất trên Sở Giao dịch Chứng khoán TP. Hồ Chí Minh) là nghiên cứu tình huống thực nghiệm được dùng cho tất cả các thí nghiệm vì nó có lịch sử dữ liệu hàng ngày dài nhất và sạch nhất. Một hệ thống tính ký quỹ định cỡ tài sản đảm bảo từ độ biến động dự báo, một bộ phận quyền chọn định giá dựa trên đó, và một cán bộ quản trị rủi ro thiết lập hạn mức vị thế dựa trên đó. Các bộ phận VN30 đưa ra những quyết định này trong một môi trường thông tin mà một mô hình dự báo chỉ-giá bỏ qua: một dòng tin tức tiếng Việt liên tục có thể báo hiệu các cú sốc biến động trước khi chúng đi vào biên độ giá, và một mạng lưới hiệu ứng lan truyền chéo giữa các cổ phiếu mà một mô hình đơn biến không thể biểu diễn.

Mô hình HAR cổ điển của Corsi [1], mô hình tuyến tính đơn biến chủ lực hồi quy độ biến động tương lai trên chính các trung bình hàng ngày, hàng tuần, và hàng tháng của nó, không chấp nhận tín hiệu nào trong hai tín hiệu trên, và rất khó bị vượt qua [14]. Hai mở rộng có cấu trúc có thể thu hẹp khoảng cách: một kênh tin tức đọc văn bản, và một đồ thị chéo giữa các cổ phiếu cho phép thông tin của một cổ phiếu đến được cổ phiếu khác. Công trình trước đó trên dự án này đã thiết lập, qua một phân tích khám phá an toàn với rò rỉ dữ liệu, rằng việc thêm các đặc trưng node cắt ngang (một yếu tố thị trường và một z-score khối lượng) vượt HAR trên QLIKE, nhưng một cạnh chéo giữa các cổ phiếu *dựa trên tương quan* không mang lại giá trị ngoài mẫu (out-of-sample) đáng tin cậy vì một yếu tố thị trường đơn lẻ chi phối sự đồng biến động chéo giữa các cổ phiếu. Điều này thúc đẩy lựa chọn thiết kế trung tâm của nghiên cứu hiện tại: thay vì một cạnh tương quan đối xứng, nghiên cứu kiểm tra một **cạnh dẫn-trễ có hướng khối lượng**→**độ biến động** — khối lượng bất thường hôm nay của một mã nguồn liên kết với độ biến động biên độ ngày mai của một mã đích — mã hóa một quan hệ dự báo, nhân quả (dẫn-trễ) mà một cạnh tương quan đồng thời không thể có.

Nghiên cứu tích hợp cạnh này vào một kiến trúc đa nhánh song song (một nhánh thời gian LSTM, một nhánh đồ thị GAT, và một nhánh tin tức có công, được ghép nối tại một head chung) và định lượng, theo từng thành phần và từng horizon, đóng góp biên của mỗi phần bằng một **ablation**: xây dựng mô hình đầy đủ, sau đó huấn luyện lại một biến thể với đúng một thành phần bị gỡ, và quy đóng góp của mỗi thành phần thành mức thay đổi QLIKE held-out mà nó gây ra. Bài báo này có ba đóng góp.

1. **Một mô hình graph-attention tin tức vol**→**PK có hướng trên một backbone đa nhánh song song**. Mô hình hợp nhất một LSTM giá theo từng node, một GAT đa đầu thực sự trên một cạnh dẫn-trễ có hướng khối lượng→độ biến động, và một

nhánh tin tức PhoBERT có cổng. GAT tiêu thụ vector đặc trưng node thô tại gốc dự báo, điều này khớp với ngữ nghĩa của cạnh và giữ cho nhánh đồ thị là một góc nhìn cắt ngang độc lập (Mục 4).

2. **Một ablation đối chiếu với một baseline HAR mạnh.** Từ mô hình đầy đủ, mỗi biến thể được huấn luyện lại theo từng thành phần bị gỡ — minus-graph (toàn bộ nhánh GAT), minus-gate, minus-news — nên mọi hiệu ứng được đo trên cùng một cơ sở, và đóng góp biên của mỗi thành phần được báo cáo là $\text{effect}(X) = \text{QLIKE}(\text{FULL}) - \text{QLIKE}(\text{FULL} - X)$ kèm kiểm định Diebold-Mariano (Mục 6).
 3. **Một đánh giá đa horizon an toàn với rò rỉ dữ liệu.** Tất cả mô hình được đánh giá tại các horizon 1, 5, 10, và 22 ngày giao dịch trên một phân chia theo thời gian với các scaler chỉ dùng dữ liệu train và một cạnh đồng cứng chỉ ước lượng trên train, với tập kiểm tra held-out là kết quả báo cáo, qua năm seed cùng các kiểm định ý nghĩa trên dự báo seed-ensembled (Mục 5 và 6).
-

2. Công trình liên quan

Chúng tôi phân nhóm công trình trước thành bốn họ và nêu vị trí của mô hình đề xuất so với từng họ.

Mô hình độ biến động kinh tế lượng. Mô hình HAR [1] và các đầu vào dựa trên biên độ của nó [2] đặt ra tiêu chuẩn cho dự báo độ biến động hàng ngày và vẫn khó bị vượt qua. HAR hồi quy độ biến động tương lai trên các trung bình trượt hàng ngày, hàng tuần, và hàng tháng, xấp xỉ tính nhớ dài của độ biến động bằng một hồi quy tuyến tính tiết kiệm. Mở rộng HARQ [15] thu nhỏ hệ số hàng ngày khi ước lượng độ biến động nhiều. Một nghiên cứu có kiểm soát quy mô lớn cho thấy các mô hình học máy đã được tinh chỉnh không vượt được một HAR được tái ước lượng cẩn thận trên QLIKE và MSE khi cả hai dùng cùng tập thông tin [14]. Các mô hình này là đơn biến và tuyến tính: không kênh nào chấp nhận văn bản, và không kênh nào ghép nối một cổ phiếu với cổ phiếu khác. Chúng tôi giữ ba thang HAR trong số các đặc trưng node và thêm các kênh tin tức và chéo giữa các cổ phiếu có hướng mà HAR bỏ qua; HAR cổ điển là baseline mà mọi thành phần phải vượt qua.

Bộ dự báo sâu và dựa trên đồ thị. Các bộ dự báo LSTM [4] nắm bắt cấu trúc thời gian phi tuyến, và các mạng graph attention [5] mô hình hóa sự ghép nối chéo giữa các tài sản; các thiết kế lai LSTM-GNN kết hợp cả hai [9]. Chen và Robert [19] dự báo độ biến động thực hiện đa biến với một đồ thị trên khoảng 500 mã S&P. Liên quan nhất, Zhang, Pu, Cucuringu và Dong [10] xây dựng một graph-neural-network HAR (GNNHAR) trên DJIA-30 và, dưới một Model Confidence Set, phát hiện rằng hiệu ứng lan truyền đồ thị chéo giữa các cổ phiếu đa bước không mang lại lợi thế rõ ràng: các mức tăng đến từ việc mô hình hóa tính phi tuyến và từ việc chuyển hàm mất mát huấn luyện từ MSE sang QLIKE. Kết quả null có kiểm soát của họ trên thành phần đồ thị thúc đẩy việc chúng tôi chuyển từ một cạnh tương quan đối xứng sang một cạnh dẫn-trễ có hướng, được kiểm tra tại đây dưới một ablation.

Đồ thị hiệu ứng lan truyền có hướng và dẫn-trễ. Một cạnh tương quan đối xứng trộn lẫn sự đồng biến động đồng thời (phần lớn là một yếu tố thị trường) với cấu trúc dự báo. Các thước đo hiệu ứng lan truyền có hướng — ví dụ các chỉ số hiệu ứng lan truyền độ biến động [16] — mã hóa ai-dẫn-ai và bất đối xứng theo cấu tạo. Chúng tôi hiện thực hóa

một cạnh có hướng từ khối lượng bất thường của một mã nguồn đến độ biến động biên độ ngày kế tiếp của một mã đích, dựa trên quan hệ dẫn-trễ khối lượng–độ biến động, và đồng cứng nó trên cửa sổ huấn luyện.

Dự báo tăng cường bằng tin tức và văn bản. Các bộ dự báo tăng cường văn bản thêm điểm cảm xúc hoặc embedding tin tức [7,8], thường hợp nhất một tín hiệu toàn thị trường đơn lẻ bằng ghép nối trên các thị trường tiếng Anh hoặc tiếng Trung. Chúng tôi làm việc bằng tiếng Việt với PhoBERT [3] trên VN30 và thêm một công theo từng mã cho phép một lượng tin tức khác nhau cho mỗi cổ phiếu.

3. Dữ liệu

Vũ trụ dữ liệu (nghiên cứu tình huống). Phương pháp hướng tới thị trường chứng khoán Việt Nam nói chung; VN30 là vũ trụ nghiên cứu tình huống cho các thí nghiệm. Chúng tôi dùng 33 cổ phiếu thành phần VN30 với dữ liệu open-high-low-close-volume (OHLCV) hàng ngày. Độ dài chuỗi trải từ khoảng 1.300 phiên (SSB, niêm yết 2021) đến khoảng 4.900 (VNM, ACB, từ 2006). Vũ trụ là một tập cố định theo thời điểm kiểu VN30 chứ không phải chỉ số động, một hạn chế được nêu trong mục Hạn chế.

Mục tiêu dự báo. Chúng tôi dự báo độ biến động biên độ Parkinson hàng ngày tại các horizon 1, 5, 10, và 22 ngày giao dịch phía trước: mục tiêu là giá trị của estimator ở một ngày đơn lẻ tại ngày $t+h$ (tức $PK(t+h)$), không phải trung bình trên h ngày kế tiếp. Estimator Parkinson dùng giá cao nhất H và thấp nhất L trong ngày:

$$\sigma_{\text{Park}}^2 = \frac{(\ln(H/L))^2}{4 \ln 2}.$$

Cột parkinson_volatility đã xử lý về mặt số học là estimator **phương sai** Parkinson (σ^2 , không âm), và mọi mô hình trong bài báo này dự báo cùng đại lượng phương sai thực hiện hàng ngày này.

Đặc trưng node. Mỗi ticker-day mang năm đặc trưng node theo một thứ tự cố định, tất cả với các cửa sổ 22 ngày giao dịch thông nhất để khớp với thang HAR hàng tháng:

1. pk_daily — phương sai Parkinson tại t , được cắt về $\pm 3\sigma$ dùng thống kê train.
2. har_weekly — trung bình 5 ngày lùi của pk_daily.
3. har_monthly — trung bình 22 ngày lùi của pk_daily.
4. market_pk — trung vị cắt ngang của $\sqrt{PK}$ qua các mã hiện diện tại t (một yếu tố thị trường đồng thời; chỉ dùng cột t).
5. volume_zscore — z-score trượt-22 lùi của $\log(1 + \text{volume})$; các mã không có chuỗi khối lượng OHLCV nhận giá trị trung tính 0.0.

Bảng tin tức. Mỗi bài báo tiếng Việt (tiêu đề và đoạn dẫn) đi qua PhoBERT [3] một lần, tạo ra một embedding 768 chiều được giảm bằng PCA (khớp trước mốc cắt huấn luyện) thành một vector theo từng ngày theo từng cổ phiếu gồm 146 chiều (các thành phần embedding, các chuẩn theo nhóm, các trung bình có trọng số mũ với chu kỳ bán rã 30 ngày giao dịch, và số đếm chủ đề). Tin tức thiếu vào một ngày là một vector không với bit mask đặt bằng không, và một cửa sổ hoàn toàn thiếu vẫn tạo ra một biểu diễn hữu hạn.


Cạnh vol→PK có hướng. Ma trận kề là có hướng: với mỗi mã đích j , chúng tôi kết nối Top-5 mã nguồn i được xếp hạng theo tương quan dẫn-trễ chỉ ước lượng trên train $\text{corr}(\text{volume_shock}_i(t), \sqrt{PK_j}(t+1))$. Các cạnh được ước lượng chỉ trên các hàng

train và đồng cứng cho validation và test (an toàn với rò rỉ dữ liệu), và các self-loop được giữ trên đường chéo.

Phân chia theo thời gian và kiểm soát rò rỉ dữ liệu. Chuỗi của mỗi mã được chia theo thời gian thành 70% train, 15% validation, và 15% test trước khi sinh đặc trưng, khớp scaler, hoặc xây cửa sổ; các chuỗi sớm nhất bắt đầu năm 2006. Phân chia được áp dụng theo từng mã trên dòng thời gian riêng của nó, nên các ranh giới lịch train/validation/test khác nhau giữa các mã — một mã niêm yết năm 2021 có các ranh giới muộn hơn một mã giao dịch từ 2006 — đó chính là lý do một bảng đồng bộ node cố định sẽ sụp đổ và tại sao phân chia gộp theo từng mã được dùng. Các scaler giả và mục tiêu theo từng mã được khớp chỉ trên phần train và được chọn khi đánh giá bằng ticker_id tường minh. Một đặc trưng tin tức cho một mẫu chỉ dùng thông tin có sẵn tính đến gốc dự báo của mẫu đó. Đánh giá đọc các mục tiêu thô đã lưu thay vì nghịch đảo biến đổi một mục tiêu chuẩn hóa đã bị cắt. Trên bảng dữ liệu gộp có mask, các tập đánh giá giữ, tại horizon năm ngày, 14.418 quan sát validation và 14.464 quan sát test node hiện diện, được chia sẽ giống hệt qua mọi bậc; số lượng thay đổi nhẹ theo horizon (ví dụ 14.550/14.596 tại h1 và 14.253/14.299 tại h10) vì dịch chuyển mục tiêu làm thay đổi số cửa sổ đủ điều kiện.

4. Phương pháp

Chúng tôi mô tả mô hình đầy đủ đề xuất trước, sau đó định nghĩa các biến thể ablation là các thao tác gỡ thành phần khỏi nó. Mô hình dự báo phương sai Parkinson h -ngày-tới của một mã từ bốn đầu vào: một cửa sổ giá 22 ngày của năm đặc trưng node, một cửa sổ tin tức 22 ngày của các đặc trưng PhoBERT với một mask, danh tính của mã, và ma trận kề vol→PK có hướng trên các mã hiện diện cùng ngày.




Kiến trúc mô hình: các nhánh song song LSTM-giá, GAT vol→PK có hướng (trên đặc trưng node thô), và nhánh tin tức PhoBERT có cổng, được ghép nối vào một head với một sản dương softplus.

Mô hình đầy đủ đề xuất. Ba nhánh chạy song song và ghép nối tại một head chung.

- **(i) Nhánh Price-LSTM (thời gian, theo từng node).** Một LSTM hai lớp (kích thước ẩn 64, dropout 0.2) đọc cửa sổ 22 ngày của năm đặc trưng node của mỗi mã thành một biểu diễn giá $h_{\text{lstm}} (\mathbb{R}^{64}$ mỗi node).
- **(ii) Nhánh đồ thị GAT (cắt ngang).** Đầu vào node là vector đặc trưng node **thô** tại bước thời gian cuối, $\text{node_raw} = \text{price}[:, :, -1, :] \in \mathbb{R}^5$, không phải trạng thái ẩn của LSTM. Hai lớp GAT đa đầu tự viết (5→256, rồi 256→256; 4 đầu) với attention được mask bởi ma trận kề (softmax trên các node nguồn, đầu ra ELU) tạo ra $h_{\text{gnn}} \in \mathbb{R}^{256}$. Việc tiêu thụ các đặc trưng thô khớp với ngữ nghĩa của cạnh (volume_shock trực tiếp có sẵn cho attention) và giữ cho nhánh đồ thị độc lập với nhánh LSTM, nên gỡ nó là một ablation sạch. Khi đồ thị bị tắt, ma trận kề là ma trận đơn vị (chỉ self-loop).
- **(iii) Nhánh tin tức với cổng theo từng mã.** Vector tin tức hàng ngày 146 chiều đi qua một phép chiếu tuyến-tính-cộng-ReLU vào một LSTM hai lớp (kích thước ẩn 64) trên cửa sổ có mask, tạo ra một biểu diễn tin tức, được nhân tỷ lệ bởi một cổng sigmoid theo từng mã đã học $\text{news}_i^{\text{gated}} = \sigma(g_i) \cdot \text{news}_i$.

Head ghép nối $[h_{\text{lstm}}(64), h_{\text{gnn}}(256), \text{news}^{\text{gated}}(64)] (\mathbb{R}^{384})$ và ánh xạ nó qua một stack tuyến-tính-ReLU-dropout-tuyến-tính đến dự báo. Một **sàn dương** softplus ($\varepsilon = 10^{-6}$, áp dụng trong không gian đã khử chuẩn hóa và giống hệt qua mọi bậc so sánh) kẹp các dự báo tránh xa phương sai không dương trước QLIKE.

Các biến thể ablation. Chúng tôi xây mô hình đầy đủ, sau đó huấn luyện lại một biến thể theo từng thành phần bị gỡ, nên mọi hiệu ứng được đo trên cùng một cơ sở (mỗi biến thể huấn luyện trong cùng chế độ đồ thị bật/tắt mà nó được đánh giá — không có sự lệch train/eval):



Ablation: từ FULL, mỗi biến thể gỡ một thành phần (–graph, –gate, –news); HAR và một mô hình LSTM-only chi-giá là các baseline tham chiếu.
 $\text{effect}(X) = \text{QLIKE}(\text{FULL}) - \text{QLIKE}(\text{FULL} - X)$.

- **FULL** — LSTM + đồ thị GAT vol→PK có hướng + tin tức + cổng theo từng mã.
- **minus_graph** — FULL với **toàn bộ nhánh GAT bị gỡ** (không xây node/cạnh/GAT; head lấy $[h_{\text{lstm}}, \text{news}^{\text{gated}}] \in \mathbb{R}^{128}$). Điều này cô lập toàn bộ hệ thống con đồ thị, không chỉ các cạnh.
- **minus_gate** — FULL không có cổng theo từng mã.

- **minus_news** — FULL không có nhánh tin tức (công là một no-op khi không có tin tức).
- **HAR** — một hồi quy tuyến tính HAR gộp theo từng mã trên ba thang HAR; sản mà mọi thành phần phải vượt qua.

Đóng góp của thành phần X là $\text{effect}(X) = \text{QLIKE}(\text{FULL}) - \text{QLIKE}(\text{FULL} - X)$ trên tập kiểm tra held-out; một giá trị âm nghĩa là gỡ X làm tăng QLIKE, tức X có ích.

Huấn luyện. Các mô hình sâu dùng Adam (tốc độ học 10^{-3}), weight decay 10^{-5} , dropout 0.2, và cắt gradient tại 1.0, với việc chọn checkpoint tốt nhất trên validation. Vì các mô hình gộp hội tụ trong vài epoch rồi overfit, huấn luyện dùng early stopping (patience 3, tối thiểu 6 epoch) dưới một trần 12 epoch. Mọi cấu hình được huấn luyện dưới năm seed (42, 123, 2026, 7, 2024); các metric test được báo cáo là mean(std) qua năm seed, và các kiểm định Diebold-Mariano chạy trên các dự báo test seed-ensembled.

5. Thiết lập thực nghiệm

Các metric. Mọi cấu hình báo cáo năm metric trên thang phương sai thô: MSE, RMSE, MAE, R^2 , và QLIKE. QLIKE, hàm mất mát tựa-hợp-lý (quasi-likelihood) chuẩn trong tài liệu độ biến động thực hiện [patton], phạt việc dự báo thiếu nặng hơn dự báo thừa và chịu được nhiễu trong proxy độ biến động:

$$\text{QLIKE} = \frac{1}{T} \sum_{t=1}^T \left(\frac{\hat{\sigma}_t^2}{\sigma_t^2} - \ln \frac{\hat{\sigma}_t^2}{\sigma_t^2} - 1 \right).$$

Hàm mục tiêu huấn luyện. Tất cả cấu hình sâu tối thiểu hóa sai số bình phương trung bình giữa đầu ra mô hình và mục tiêu chuẩn hóa theo từng mã; QLIKE và các metric khác chỉ được tính khi đánh giá, sau khi nghịch đảo chuẩn hóa về thang phương sai thô, nên hàm mất mát QLIKE tỷ lệ không bao giờ đi vào gradient.

Giao thức báo cáo. Việc chọn mô hình (early-stopping, best-checkpoint) chỉ dùng phân chia validation; tất cả kết quả báo cáo và kiểm định ý nghĩa được tính trên tập kiểm tra held-out; validation chỉ được dùng để chọn mô hình, và không có metric validation nào được báo cáo.

Ý nghĩa thống kê. Chúng tôi bổ sung so sánh metric bằng một kiểm định Diebold-Mariano (DM) trên chuỗi mất mát QLIKE (và sai số bình phương) theo từng quan sát (độ trễ cắt HAC $h=1$, hiệu chỉnh Harvey-Leybourne-Newbold), kiểm tra tính bằng nhau về độ chính xác dự báo trực tiếp trên các quan sát held-out. Kiểm định DM chạy trên các dự báo seed-ensembled (dự báo trung bình theo từng quan sát qua các seed 42, 123, 2026, 7, 2024).

Hiện thực và tính toán. Tất cả mô hình được hiện thực bằng PyTorch (lớp GAT tự viết; không dùng thư viện đồ thị bên ngoài) và dùng một GPU CUDA. Các lần chạy dùng một GPU NVIDIA GeForce RTX 4060 Laptop dưới PyTorch 2.6 với CUDA 12.4.

6. Kết quả

6.1 Các metric test held-out qua các horizon

Bảng 1. Các metric TEST held-out theo horizon, mean(std) qua năm seed (42, 123, 2026, 7, 2024). Thấp hơn là tốt hơn cho MSE, RMSE, MAE, QLIKE; cao hơn cho R^2 . In đậm đánh dấu giá trị trung bình tốt nhất mỗi cột trong từng horizon; cùng các quan sát test được chia sẻ qua mọi hàng của một horizon. HAR là một hồi quy tuyến tính xác định (std 0.00).

h = 1 ngày giao dịch

Config	MSE ($\times 10^{-6}$) ↓	RMSE ($\times 10^{-3}$) ↓	MAE ($\times 10^{-4}$) ↓	R^2 ↑	QLIKE ↓
HAR	4.05 (0.00)	2.014 (0.000)	5.41 (0.00)	0.8192 (0.0000)	0.4813 (0.0000)
FULL	4.03 (0.08)	2.006 (0.021)	5.46 (0.07)	0.8205 (0.0037)	0.4831 (0.0063)
minus_graph	4.03 (0.05)	2.009 (0.012)	5.41 (0.04)	0.8201 (0.0021)	0.4798 (0.0036)
minus_gate	4.00 (0.08)	2.000 (0.021)	5.43 (0.06)	0.8217 (0.0037)	0.4816 (0.0062)
minus_news	4.02 (0.07)	2.004 (0.017)	5.44 (0.08)	0.8209 (0.0030)	0.4810 (0.0061)
LSTM-only	4.07 (0.08)	2.018 (0.019)	5.42 (0.11)	0.8184 (0.0035)	0.4803 (0.0044)

h = 5 ngày giao dịch

Config	MSE ($\times 10^{-6}$) ↓	RMSE ($\times 10^{-3}$) ↓	MAE ($\times 10^{-4}$) ↓	R^2 ↑	QLIKE ↓
HAR	5.23 (0.00)	2.287 (0.000)	6.05 (0.00)	0.7672 (0.0000)	0.5735 (0.0000)
FULL	5.20 (0.07)	2.281 (0.015)	5.98 (0.06)	0.7685 (0.0031)	0.5773 (0.0028)
minus_graph	5.21 (0.04)	2.282 (0.010)	5.98 (0.07)	0.7683 (0.0020)	0.5795 (0.0054)
minus_gate	5.21 (0.07)	2.283 (0.016)	5.99 (0.05)	0.7680 (0.0032)	0.5768 (0.0031)
minus_news	5.22 (0.07)	2.284 (0.015)	5.99 (0.06)	0.7679 (0.0031)	0.5773 (0.0032)
LSTM-only	5.20 (0.05)	2.281 (0.011)	5.98 (0.08)	0.7685 (0.0023)	0.5812 (0.0068)

h = 10 ngày giao dịch

Config	MSE ($\times 10^{-6}$) ↓	RMSE ($\times 10^{-3}$) ↓	MAE ($\times 10^{-4}$) ↓	R^2 ↑	QLIKE ↓
HAR	5.56 (0.00)	2.358 (0.000)	6.30 (0.00)	0.7532 (0.0000)	0.6139 (0.0000)
FULL	5.61 (0.12)	2.368 (0.024)	6.27 (0.08)	0.7512 (0.0051)	0.6369 (0.0279)
minus_graph	5.57 (0.10)	2.359 (0.022)	6.31 (0.05)	0.7530 (0.0046)	0.6196 (0.0033)
minus_gate	5.57 (0.10)	2.360 (0.021)	6.30 (0.09)	0.7529 (0.0043)	0.6242 (0.0040)
minus_news	5.61 (0.12)	2.369 (0.025)	6.28 (0.11)	0.7509 (0.0053)	0.6464 (0.0443)
LSTM-only	5.56 (0.10)	2.358 (0.021)	6.29 (0.06)	0.7533 (0.0044)	0.6195 (0.0034)

$h = 22$ ngày giao dịch

Config	MSE ($\times 10^{-6}$) ↓	RMSE ($\times 10^{-3}$) ↓	MAE ($\times 10^{-4}$) ↓	R^2 ↑	QLIKE ↓
HAR	6.02 (0.00)	2.453 (0.000)	6.56 (0.00)	0.7303 (0.0000)	0.6742 (0.0000)
FULL	6.23 (0.29)	2.495 (0.058)	6.58 (0.14)	0.7210 (0.0131)	0.7074 (0.0071)
minus_graph	6.17 (0.12)	2.485 (0.023)	6.51 (0.04)	0.7234 (0.0052)	0.6979 (0.0112)
minus_gate	6.21 (0.19)	2.493 (0.037)	6.57 (0.09)	0.7216 (0.0084)	0.7082 (0.0113)
minus_news	6.17 (0.11)	2.484 (0.023)	6.56 (0.07)	0.7235 (0.0051)	0.7078 (0.0091)
LSTM-only	6.12 (0.04)	2.474 (0.008)	6.54 (0.05)	0.7258 (0.0018)	0.6982 (0.0058)

Đọc qua các horizon: trên các metric sai số bình phương (MSE, RMSE, R^2), các giá trị trung bình của các cấu hình nằm trong khoảng 1% so với nhau và hàng tốt nhất luân phiên (minus_gate tại h1, FULL/LSTM-only tại h5, LSTM-only tại h10, HAR tại h22); trên MAE khác biệt cũng nhỏ tương tự và giá trị trung bình thấp nhất thay đổi theo horizon (HAR/minus_graph tại h1, ba cấu hình gần bằng nhau quanh 5.98 tại h5, FULL tại h10, minus_graph tại h22); trên QLIKE, HAR có giá trị trung bình thấp nhất tại h5, h10, và h22 còn minus_graph có giá trị trung bình thấp nhất tại h1. Các độ lệch chuẩn báo cáo là nhỏ so với khoảng cách giữa các cấu hình ngoại trừ tại h10, nơi các giá trị trung bình QLIKE của FULL và minus_news mang độ phân tán seed lớn hơn (std 0.028 và 0.044). Các tiêu mục còn lại cô lập từng thành phần (Mục 6.2), so sánh FULL với HAR (Mục 6.3), và kiểm tra ý nghĩa thống kê (Mục 6.4).

6.2 Đóng góp thành phần qua các horizon

Bảng 2. Đóng góp thành phần trên QLIKE test held-out,
 $\text{effect}(X) = \text{QLIKE}(\text{FULL}) - \text{QLIKE}(\text{FULL} - X)$, trung bình năm seed. Âm = gỡ
 X làm tăng QLIKE, tức X có ích.

Horizon	effect(graph)	effect(gate)	effect(news)
1	+0.00337	+0.00158	+0.00212
5	−0.00211	+0.00056	+0.00009
10	+0.01737	+0.01271	−0.00949
22	+0.00953	−0.00080	−0.00036

Đọc: effect(graph) dương tại h1, h10, và h22 (gỡ nhánh GAT làm giảm QLIKE ở đó) và âm nhẹ tại h5 (−0.0021). effect(gate) dương tại h1, h5, và h10 và âm nhẹ tại h22 (−0.0008). effect(news) dương tại h1 và h5 và âm tại h10 (−0.0095) và h22 (−0.0004), nên gỡ nhánh tin tức làm tăng QLIKE chỉ tại các horizon dài hơn. Đây là các hiệu ứng QLIKE; các khác biệt MSE, RMSE, và R^2 tương ứng giữa cùng các cấu hình nằm trong khoảng 1% (Bảng 1). Các độ lớn tại h10 là lớn nhất, nhưng độ phân tán seed tại h10 (Bảng 1) cũng là lớn nhất; kiểm định Diebold-Mariano (Mục 6.4) xác định khác biệt nào có ý nghĩa trên các dự báo seed-ensembled.

6.3 FULL so với HAR qua các horizon

Bảng 3. FULL so với HAR, test held-out, cả bốn horizon, mean(std) qua năm seed.
Các cột ghép mỗi metric theo thứ tự HAR-rời-FULL; in đậm đánh dấu giá trị trung bình tốt hơn của cặp.

Horizon	HAR QLIKE	FULL QLIKE	HAR R^2	FULL R^2	HAR RMSE ($\times 10^{-3}$)	FULL RMSE ($\times 10^{-3}$)
1	0.4813 (0.0000)	0.4831 (0.0063)	0.8192 (0.0000)	0.8205 (0.0037)	2.014 (0.000)	2.006 (0.021)
5	0.5735 (0.0000)	0.5773 (0.0028)	0.7672 (0.0000)	0.7685 (0.0031)	2.287 (0.000)	2.281 (0.015)
10	0.6139 (0.0000)	0.6369 (0.0279)	0.7532 (0.0000)	0.7512 (0.0051)	2.358 (0.000)	2.368 (0.024)
22	0.6742 (0.0000)	0.7074 (0.0071)	0.7303 (0.0000)	0.7210 (0.0131)	2.453 (0.000)	2.495 (0.058)

Đọc: trên RMSE và R^2 mô hình đầy đủ có giá trị trung bình nhỉnh hơn tại h1 và h5 còn HAR nhỉnh hơn tại h10 và h22, nhưng các khác biệt nằm trong độ phân tán seed (kiểm định DM sai số bình phương không có khác biệt có ý nghĩa tại bất kỳ horizon nào; MSE và MAE theo cùng khuôn mẫu trong Bảng 1). Trên QLIKE, HAR có giá trị trung bình thấp hơn tại cả bốn horizon, với khoảng cách mở rộng từ h1 (0.0018) đến h22 (0.0332). Bảng Diebold-Mariano (Bảng 4) kiểm tra các khoảng cách này qua các họ mất mát trên dự báo seed-ensembled: trên QLIKE, mô hình đầy đủ không có khác biệt có ý nghĩa so với HAR tại h1, h5, và h10 và HAR thấp hơn có ý nghĩa tại h22; trên sai số bình phương không có khác biệt có ý nghĩa tại bất kỳ horizon nào; trên sai số tuyệt đối, mô hình đầy đủ thấp hơn có ý nghĩa tại h5.

6.4 Ý nghĩa thống kê Diebold-Mariano qua các metric

Bảng 4. Diebold-Mariano (HLN) trên test held-out, seed-ensembled (42, 123, 2026, 7, 2024), theo từng horizon và từng họ mất mát. Mỗi ô là thống kê DM hiệu chỉnh HLN kèm p -value hai phía; **in đậm** đánh dấu $p < 0.05$. Một thống kê **âm** nghĩa là FULL có mất mát thấp hơn; một thống kê **đương** nghĩa là đối tượng so sánh có mất mát thấp hơn. DM chạy trên ba họ mất mát theo từng quan sát: QLIKE, sai số bình phương (SE; họ MSE/RMSE/ R^2), và sai số tuyệt đối (AE; MAE). Độ trễ cắt HAC $h-1$; n theo từng horizon là 14.596 (h1), 14.464 (h5), 14.299 (h10), 13.903 (h22).

h = 1 ngày giao dịch

Comparison	QLIKE	SE (MSE/RMSE/ R^2)	AE (MAE)
FULL vs HAR	-1.09 ($p = 0.28$)	-1.72 ($p = 0.09$)	+0.79 ($p = 0.43$)
FULL vs minus_graph	+6.16 ($p < 0.001$)	-1.77 ($p = 0.08$)	+3.33 ($p < 0.001$)
FULL vs minus_gate	+7.55 ($p < 0.001$)	+1.57 ($p = 0.12$)	+5.52 ($p < 0.001$)
FULL vs minus_news	+8.99 ($p < 0.001$)	+0.74 ($p = 0.46$)	+4.81 ($p < 0.001$)
FULL vs LSTM- only	+8.77 ($p < 0.001$)	-2.99 ($p < 0.001$)	+2.68 ($p = 0.01$)

h = 5 ngày giao dịch

Comparison	QLIKE	SE (MSE/RMSE/ R^2)	AE (MAE)
FULL vs HAR	-1.11 ($p = 0.27$)	-0.99 ($p = 0.32$)	-3.97 ($p < 0.001$)
FULL vs minus_graph	-0.51 ($p = 0.61$)	-0.43 ($p = 0.67$)	-0.82 ($p = 0.41$)
FULL vs minus_gate	-5.27 ($p < 0.001$)	-1.86 ($p = 0.06$)	-3.36 ($p < 0.001$)
FULL vs minus_news	-0.03 ($p = 0.97$)	-2.42 ($p = 0.02$)	-2.54 ($p = 0.01$)
FULL vs LSTM- only	-1.94 ($p = 0.05$)	-0.18 ($p = 0.85$)	+0.22 ($p = 0.82$)

h = 10 ngày giao dịch

Comparison	QLIKE	SE (MSE/RMSE/ R^2)	AE (MAE)
FULL vs HAR	+1.84 ($p = 0.07$)	+0.35 ($p = 0.73$)	-1.90 ($p = 0.06$)
FULL vs minus_graph	+1.55 ($p = 0.12$)	+2.09 ($p = 0.04$)	-4.53 ($p < 0.001$)
FULL vs minus_gate	+0.45 ($p = 0.65$)	+2.09 ($p = 0.04$)	-4.18 ($p < 0.001$)

Comparison	QLIKE	SE (MSE/RMSE/ R^2)	AE (MAE)
FULL vs minus_news	+1.27 ($p = 0.20$)	+0.63 ($p = 0.53$)	-1.09 ($p = 0.28$)
FULL vs LSTM- only	+1.78 ($p = 0.08$)	+2.35 ($p = 0.02$)	-3.74 ($p < 0.001$)

$h = 22$ ngày giao dịch

Comparison	QLIKE	SE (MSE/RMSE/ R^2)	AE (MAE)
FULL vs HAR	+4.13 ($p < 0.001$)	+1.73 ($p = 0.08$)	-0.41 ($p = 0.68$)
FULL vs minus_graph	+1.40 ($p = 0.16$)	+0.84 ($p = 0.40$)	+2.80 ($p = 0.01$)
FULL vs minus_gate	-0.25 ($p = 0.80$)	+0.20 ($p = 0.84$)	+0.40 ($p = 0.69$)
FULL vs minus_news	-2.14 ($p = 0.03$)	+0.74 ($p = 0.46$)	+0.25 ($p = 0.81$)
FULL vs LSTM- only	+1.26 ($p = 0.21$)	+1.98 ($p = 0.05$)	+1.53 ($p = 0.13$)

Đọc (tất cả họ mất mát): Với FULL vs HAR, mất mát QLIKE khác biệt có ý nghĩa chỉ tại h22 (HAR thấp hơn, $p < 0.001$) không có khác biệt có ý nghĩa tại h1, h5, hay h10; mất mát sai số bình phương không có khác biệt có ý nghĩa tại bất kỳ horizon nào; mất mát sai số tuyệt đối khác biệt có ý nghĩa chỉ tại h5 (FULL thấp hơn, $p < 0.001$). Không mô hình đơn lẻ nào có mất mát thấp hơn qua cả ba họ. Với các thao tác gỡ thành phần, ý nghĩa thống kê phụ thuộc vào hàm mất mát và horizon: gỡ nhánh GAT có ý nghĩa trên QLIKE chỉ tại h1 và trên mất mát sai số bình phương chỉ tại h10; gỡ cổng theo từng mã có ý nghĩa trên QLIKE tại h1 và h5; gỡ nhánh tin tức có ý nghĩa trên QLIKE tại h1 và h22. Backbone LSTM chỉ-giá có mất mát thấp hơn hoặc bằng so với mô hình đầy đủ trên QLIKE tại h1. Qua cả ba họ mất mát, không cấu hình nào được ưu tiên đồng nhất so với HAR.

7. Thảo luận

Mỗi thành phần đóng góp gì. Bảng 2 báo cáo đóng góp QLIKE biên của mỗi thành phần, và Bảng 4 ý nghĩa thống kê của nó trên các dự báo seed-ensembled; trên các metric MSE, RMSE, và R^2 , cùng các cấu hình khác biệt khoảng 1% hoặc ít hơn (Bảng 1). Với nhánh GAT, gỡ nó làm giảm QLIKE có ý nghĩa tại h1 ($p < 0.001$) và không có khác biệt có ý nghĩa tại h5, h10, hay h22, nên cạnh dẫn-trễ có hướng — thiết kế được chọn cụ thể để tránh sự dư thừa yếu-tổ-thị-trường của một cạnh tương quan — không tạo ra cải thiện QLIKE ngoài mẫu có ý nghĩa tại bất kỳ horizon nào. Điều này nhất quán với phát hiện cạnh-tương-quan trước đó: chuyển hướng cạnh sang một quan hệ dự báo khối lượng→độ biến động và đưa cho attention các đặc trưng thô không tạo ra một cải thiện QLIKE. Với nhánh tin tức, gỡ nó làm giảm QLIKE có ý nghĩa tại h1 và làm tăng nó có ý nghĩa tại h22 ($p = 0.03$), nên nhánh tin tức làm giảm QLIKE chỉ tại h22. Với cổng, gỡ nó làm giảm

QLIKE có ý nghĩa tại h1 và làm tăng nó có ý nghĩa tại h5, và không có khác biệt có ý nghĩa tại h10 hay h22. So với HAR, mô hình đầy đủ không có khác biệt QLIKE có ý nghĩa tại h1, h5, và h10 và có QLIKE cao hơn có ý nghĩa tại h22 (Bảng 4).

Backbone chỉ-giá so với ngăn xếp đầy đủ. Mô hình tham chiếu LSTM-only (một LSTM giả gộp chung không tin tức, không công, không đồ thị) có QLIKE test năm seed 0.4803 / 0.5812 / 0.6195 / 0.6982 tại h1 / h5 / h10 / h22, và kiểm định DM seed-ensembled phát hiện nó có QLIKE thấp hơn có ý nghĩa so với mô hình đầy đủ chỉ tại h1 (không có khác biệt có ý nghĩa tại h5, h10, hay h22). So với HAR, cả LSTM-only và mô hình đầy đủ đều không có lợi thế QLIKE có ý nghĩa tại h1–h10 và có QLIKE cao hơn HAR tại h22, nên mô hình thời gian sâu bằng HAR ở các horizon ngắn và không vượt qua baseline tuyến tính ở horizon dài.

Độc tổng thể. Qua năm seed và cả năm metric, không cấu hình nào vượt HAR một cách nhất quán hoặc có ý nghĩa. Trên MSE, RMSE, MAE, và R^2 các cấu hình khác biệt khoảng 1% hoặc ít hơn, trong độ phân tán seed, tại mọi horizon; trên QLIKE, HAR không có khác biệt có ý nghĩa so với mô hình đầy đủ tại h1, h5, và h10 và có giá trị thấp hơn có ý nghĩa tại h22, và backbone LSTM chỉ-giá có QLIKE thấp hơn có ý nghĩa so với mô hình đầy đủ tại h1. Các thành phần đồ thị, công, và tin tức không cung cấp một cải thiện có ý nghĩa nhất quán qua các horizon trên bất kỳ metric nào.

Liên hệ với tài liệu. Một hiệu ứng đồ thị null hoặc không đáng kể phù hợp với nghiên cứu GNN-vs-HAR được kiểm soát tốt nhất đã công bố, GNNHAR trên DJIA-30, nơi hiệu ứng lan truyền đồ thị đa bước không mang lại lợi thế rõ ràng dưới một Model Confidence Set và các mức tăng dần từ tính phi tuyến và một hàm mất mát huấn luyện QLIKE thay vì đồ thị [10], và với phát hiện rộng hơn rằng một HAR được đặc tả tốt rất khó bị vượt qua trên một tập thông tin hạn chế [14].

Các đòn bẩy không được thực thi ở đây. Tài liệu xác định một hàm mục tiêu huấn luyện QLIKE và phương sai thực hiện dẫn xuất từ dữ liệu trong ngày (intraday) là các đòn bẩy quyết định để vượt HAR [10]; nghiên cứu này huấn luyện trên MSE và dự báo một phương sai hàng ngày dựa trên biên độ, nên ablation cô lập kiến trúc chứ không phải hàm mục tiêu hay estimator. Những điều này vẫn là công việc tương lai.

8. Hạn chế

Thứ nhất, vũ trụ 33 mã là một tập cố định theo thời điểm kiểu VN30 chứ không phải chỉ số động. Thứ hai, nghiên cứu bao phủ một thị trường đơn lẻ ở tần suất hàng ngày; kết quả có thể không chuyên giao sang các tần suất cao hơn hoặc sang các thị trường có lịch sử niêm yết cân bằng, và mọi kết quả GNN-vượt-HAR nghiêm ngặt đã công bố dựa vào phương sai thực hiện dẫn xuất từ dữ liệu trong ngày mà bảng dữ liệu OHLCV hàng ngày này không có. Thứ ba, các con số báo cáo tổng hợp năm seed (42, 123, 2026, 7, 2024) với các kiểm định Diebold-Mariano seed-ensembled; một Model Confidence Set là công việc tương lai khả thi để thắt chặt thêm các ước lượng ý nghĩa thống kê. Thứ tư, huấn luyện dùng một hàm mục tiêu MSE thay vì hàm mục tiêu QLIKE mà tài liệu ghi công cho việc thu hẹp khoảng cách HAR.

9. Kết luận

Chúng tôi đề xuất một mô hình đa nhánh song song cho dự báo phương sai Parkinson VN30 đa horizon hợp nhất một LSTM giá, một GAT đa đầu thực sự trên một cạnh dẫn-trễ có hướng khối lượng→độ biến động, và một nhánh tin tức PhoBERT có công, với GAT tiêu thụ các đặc trưng node thô để khớp với ngữ nghĩa của cạnh. Chúng tôi đánh giá nó bằng một ablation huấn luyện lại một biến thể theo từng thành phần bị gỡ và quy đóng góp của mỗi thành phần thành mức thay đổi mà nó gây ra trong QLIKE held-out, đối chiếu với một baseline HAR mạnh và với ý nghĩa thống kê Diebold-Mariano seed-ensembled, tại các horizon 1, 5, 10, và 22 ngày giao dịch qua năm seed. Qua cả năm metric, không cấu hình nào vượt HAR một cách nhất quán hoặc có ý nghĩa: trên MSE, RMSE, MAE, và R^2 các cấu hình khác biệt khoảng 1% hoặc ít hơn tại mọi horizon, và trên QLIKE mô hình đầy đủ không có khác biệt có ý nghĩa so với HAR tại h1, h5, và h10 và có giá trị cao hơn có ý nghĩa tại h22. Các thao tác gỡ thành phần trong ablation cho các hiệu ứng QLIKE hỗn hợp, phần lớn ở horizon ngắn — gỡ nhánh GAT làm giảm QLIKE có ý nghĩa tại h1, gỡ công theo từng mã làm giảm QLIKE tại h1 và làm tăng nó tại h5, và gỡ nhánh tin tức làm giảm QLIKE tại h1 trong khi làm tăng nó tại h22 — và một backbone LSTM chỉ-giá có QLIKE thấp hơn có ý nghĩa so với mô hình đầy đủ tại h1. Với một thị trường mới nổi Việt Nam, nghiên cứu cho thấy cách xây dựng và đánh giá một cách trung thực một bộ dự báo tin tức graph-attention với hiệu ứng lan truyền có hướng đối chiếu với HAR chuẩn ngành.

Tài liệu tham khảo

- [1] Corsi, F. A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics* 7(2), 174–196 (2009).
- [2] Parkinson, M. The extreme value method for estimating the variance of the rate of return. *The Journal of Business* 53(1), 61–65 (1980).
- [3] Nguyen, D.Q., Nguyen, A.T. PhoBERT: Pre-trained language models for Vietnamese. In *Findings of EMNLP 2020*, 1037–1042.
- [patton] Patton, A.J. Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics* 160(1), 246–256 (2011).
- [4] Hochreiter, S., Schmidhuber, J. Long short-term memory. *Neural Computation* 9(8), 1735–1780 (1997).
- [5] Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y. Graph attention networks. In *ICLR* (2018).
- [7] Ouyang, Z.-S., Yang, X.-T., Lai, Y. Systemic financial risk early warning of financial market in China using an Attention-LSTM model. *North American Journal of Economics and Finance* 56, 101383 (2021).
- [8] Das, N., Sadhukhan, B., Chatterjee, R., Chakrabarti, S. Integrating sentiment analysis with graph neural networks for enhanced stock prediction. *Decision Analytics Journal* 10, 100417 (2024).
- [9] Sonani, M.S., Badii, A., Moin, A. Stock price prediction using a hybrid LSTM-GNN model. arXiv preprint arXiv:2502.15813 (2025).

- [10] Zhang, C., Pu, X., Cucuringu, M., Dong, X. Forecasting realized volatility with spillover effects: perspectives from graph neural networks (GNNHAR). *International Journal of Forecasting* 41(1), 377–397 (2025). arXiv:2308.01419.
- [14] Audrino, F., Chassot, J. HARd to beat: the overlooked impact of rolling windows in the era of machine learning. *International Journal of Forecasting* (2025). arXiv:2406.08041.
- [15] Bollerslev, T., Patton, A.J., Quaadvlieg, R. Exploiting the errors: a simple approach for improved volatility forecasting (HARQ). *Journal of Econometrics* 192(1), 1–18 (2016).
- [16] Diebold, F.X., Yilmaz, K. Better to give than to receive: predictive directional measurement of volatility spillovers. *International Journal of Forecasting* 28(1), 57–66 (2012).
- [19] Chen, Q., Robert, C.-Y. Multivariate realized volatility forecasting with graph neural network. In *ACM ICAIF* (2022). arXiv:2112.09015.